

Inteligencia de Mercado Inmobiliario

Rentabilidad de inversión en CABA para el pequeño inversor

Informe Ejecutivo — Primera Pre-Entrega

Estrategia, arquitectura del problema y recolección de datos

82.04 Analítica Descriptiva — ITBA

Avisos relevados	14.867
Variables por aviso	55
Barrios cubiertos	48 de 48
Fuente	RE/MAX Argentina (API)
Período	Agosto 2026

Resumen ejecutivo

El mercado inmobiliario argentino es el destino habitual del ahorro en dólares, pero es un mercado **opaco**: no existe un registro público de precios de cierre, la oferta está dispersa en decenas de portales con criterios distintos, y la asimetría de información favorece sistemáticamente a quien vende.

El pequeño inversor decide, con información anecdótica, una operación que compromete el ahorro de toda una vida. No existe una fuente pública que relacione, para un mismo tipo de inmueble y una misma zona, el precio de venta con el de alquiler. Esa relación es precisamente la que determina si una compra es buen negocio.

Esta etapa construyó esa materia prima. Se relevaron **14.867 avisos** con **55 variables** cada uno, cubriendo los **48 barrios** de CABA en operaciones de venta y alquiler. Donde antes había avisos sueltos en una web, ahora hay una base estructurada y reproducible.

Lo que se definió

Componente	Definición
Cliente	Pequeño inversor particular que compra una unidad para renta
Objetivo	Estimar rentabilidad esperada con su margen de error
KPIs	4 indicadores con definición matemática y lectura comercial
Hipótesis	4 supuestos con su criterio de validación
Fuentes externas	7 bases públicas identificadas para el enriquecimiento

Lo que se construyó

Componente	Resultado
Extractores	4 portales evaluados, 1 seleccionado por criterio de consistencia
Dataset	14.867 avisos x 55 variables, 100% de los barrios
Tipos de dato	12 numéricas, 8 textuales, 2 ordinales, 23 dicotómicas
Documentación	4 desafíos técnicos diagnosticados y resueltos
Reproducibilidad	Pipeline ejecutable con dos comandos

El hallazgo técnico de la etapa

Tres de los cuatro portales devolvían **cero avisos sin generar ningún error**: status HTTP 200, respuestas de tamaño normal, ninguna excepción. El diagnóstico reveló que el contenido era 78% de bytes no imprimibles — no era HTML sino un blob binario comprimido que la librería no sabía descomprimir. Un fallo silencioso, indistinguible de un cambio de selectores. Se detalla en la sección 5.

1. El problema y el cliente


La problemática

La asimetría de información domina el mercado inmobiliario: quien vende sabe más que quien compra. Afirmaciones como “*comprá en Palermo que siempre se alquila*” circulan como sentido común sin ningún respaldo cuantitativo, y son la base sobre la que se deciden inversiones de seis cifras.

El interlocutor

Pequeño inversor particular. Una persona con ahorros en dólares —típicamente entre USD 80.000 y 200.000— que evalúa comprar **una sola unidad** en CABA para ponerla en alquiler. No es un desarrollador ni un fondo: hace esta operación una o dos veces en su vida.

Característica	Consecuencia para el análisis
Compra una unidad, no una cartera	No puede diversificar: el error impacta el 100% del capital
Ticket acotado	El 57% de la oferta está bajo USD 150.000: ese es su universo
Prioriza previsibilidad	Un punto extra de renta no compensa tres meses de vacancia
Sin acceso a información profesional	Decide con los mismos avisos públicos que este proyecto releva



2. Objetivo, alcance y usuario

Dotar al pequeño inversor de una estimación cuantificada de la rentabilidad esperada de cualquier inmueble en venta de CABA, junto con el margen de error de esa estimación, para que pueda comparar alternativas concretas sobre evidencia en lugar de sobre percepciones del mercado.

Capacidad	Qué resuelve
Estimar	Predecir cuánto se alquilaría un inmueble hoy publicado en venta
Comparar	Ordenar barrios y tipologías distinguiendo señal de ruido
Advertir	Explicitar la incertidumbre de cada estimación

Alcance

Incluye avisos de venta y alquiler publicados en CABA por RE/MAX, relevados en agosto de 2026, cubriendo los 48 barrios y las 15 comunas.

Excluye del análisis posterior cocheras, oficinas, locales, terrenos, depósitos y hoteles: no responden a la tesis de inversión del cliente definido. Se capturan igual en la extracción y se filtran en la etapa de curaduría.

Limitaciones declaradas

Limitación	Implicancia
Fuente única (RE/MAX)	Describe su cartera, no el mercado completo
Corte temporal único	No permite series ni estacionalidad
Precios de publicación	El precio de cierre suele ser menor
7,4 ventas por alquiler	Condiciona cómo podrá estimarse el alquiler esperado

Usuario final

El inversor no programa, no interpreta un coeficiente de determinación y no va a leer un notebook. Eso impone tres restricciones de diseño para las etapas siguientes: los resultados deben ser legibles sin conocimiento estadístico, la incertidumbre debe expresarse en las unidades de su decisión, y la herramienta debe responder su pregunta real —“¿este departamento es una buena compra?”— y no una pregunta agregada sobre el mercado.

Lo que este análisis no se propone: estimar la revalorización del inmueble, sustituir la inspección física o la verificación legal, ni predecir precios de cierre.

3. Indicadores clave

Cada indicador se define en dos planos: la fórmula que lo calcula y la decisión que le permite tomar al inversor. Se definen en esta etapa y se calcularán sobre el dataset en las siguientes.

KPI 1 — Rentabilidad Bruta Anual

$(\text{Alquiler mensual estimado} \times 12) / \text{Precio de venta} \times 100$

Rendimiento del capital antes de costos. Es el indicador de **cribado**: permite descartar rápido lo que rinde por debajo del mercado. No es lo que el inversor va a cobrar.

KPI 2 — Rentabilidad Neta Anual

$\text{Bruta} \times (1 - \text{vacancia}) \times (1 - \text{gastos})$

El ingreso que efectivamente queda en el bolsillo. Es el número que se compara contra un plazo fijo o un bono. Descuenta la vacancia —los meses sin inquilino entre contratos— y los gastos del propietario: administración, ABL, expensas extraordinarias y mantenimiento. Las expensas ordinarias no se descuentan porque en CABA las paga el inquilino.

KPI 3 — Meses de repago

$\text{Precio de venta} / \text{Alquiler mensual estimado}$

Cuánto tarda la inversión en devolver el capital vía renta. Es el más intuitivo para quien no maneja porcentajes de retorno, y funciona además como control de sanidad: un repago anormalmente corto señala un error en los datos.

KPI 4 — Banda de incertidumbre

$\text{Rentabilidad Bruta} \times (1 \pm \text{error de estimacion})$

Evita decidir sobre diferencias que no son reales. Si dos propiedades estiman rentabilidades parecidas y el margen de error las solapa, la diferencia es indistinguible del ruido. Para quien compra una sola propiedad y no puede promediar errores entre varias, es tan importante como el rendimiento mismo.

4. Hipótesis a validar

Cuatro supuestos declarados antes de analizar los datos, cada uno con su criterio de validación definido de antemano.

Hipótesis	Cómo se testea
H1 — La rentabilidad bruta es inversamente proporcional al precio del m ² del barrio	Correlación de Spearman entre precio mediano por m ² y rentabilidad, por barrio
H2 — El precio por m ² decrece con la distancia al subte, con un radio de influencia	Cruce espacial con bocas de subte del GCBA, controlando por barrio
H3 — Los inmuebles “a reciclar” cotizan con descuento sobre su valor esperado	Comparación del precio observado contra el predicho por un modelo de características
H4 — La antigüedad pesa más en el precio de venta que en el de alquiler	Comparación del coeficiente de antigüedad en dos modelos análogos

Preguntas de investigación por nivel de análisis

Nivel	Preguntas
Descriptivo	Precio por m ² y su dispersión por barrio; variación según antigüedad; distribución espacial de la oferta; frecuencia de amenities; porcentaje de stock apto crédito
Diagnóstico	Qué características explican el precio de alquiler; cuánto pesa la ubicación frente a los atributos; qué prima paga el mercado por cochera, balcón o seguridad
Predictivo	Cuánto se alquilaría un inmueble hoy en venta; qué rentabilidad esperada tiene cada propiedad; con qué margen de error
Prescriptivo	En qué barrios conviene comprar; qué combinación de barrio, tipología y superficie optimiza rentabilidad y riesgo; si conviene pagar la prima por amenities

5. Construcción de la base de datos


Elección de la fuente

Se desarrollaron extractores para cuatro portales. Se optó por **RE/MAX** a través de su API pública.

Portal	Método	Resultado
Argenprop	HTML server-rendered	Funcional — descartado por unicidad
MercadoLibre	HTML + JSON embebido	Funcional — descartado por unicidad
Zonaprop	HTML + JSON embebido	Bloqueado por DataDome
RE/MAX	API JSON pública	Fuente elegida

Por qué una sola fuente. Consolidar cuatro portales exige un cruce por dirección, superficie y precio para detectar el mismo inmueble publicado en varios sitios. Ese cruce es impreciso y arrastra un error difícil de cuantificar. Además, cada portal normaliza distinto los barrios, las superficies y las tipologías. Se priorizó la **consistencia interna** sobre el volumen bruto.

Ventaja adicional. RE/MAX es la única de las cuatro fuentes que expone latitud y longitud confiables, lo que habilita los cruces espaciales previstos para las etapas siguientes.



Tipos de dato capturados


El esquema unificado cubre los cuatro tipos que exige la consigna.

Tipo	Cant.	Ejemplos
Numéricas	12	precio, superficie, ambientes, antigüedad, coordenadas
Textuales y categóricas	8	operación, tipo, barrio, calle, descripción
Ordinales	2	comuna, piso
Dicotómicas	23	cochera, balcón, amenities, apto crédito, a reciclar

El precio se captura separado en valor numérico y moneda, no como cadena de texto. Es una mejora sobre el script base provisto, que lo dejaba como "USD 145.000": imposible de promediar.

El barrio se normaliza contra los 48 barrios oficiales de CABA, resolviendo alias como *Palermo Hollywood* a *Palermo* o *Once* a *Balvanera*, y de él se deriva la comuna.

Las 23 variables dicotómicas se construyen aplicando expresiones regulares sobre el texto libre de título, descripción y detalles de cada aviso.



Las variables de interés declaradas —barrio, superficie, ambientes, antigüedad y precio— se capturaron con alta cobertura. La captura se realizó entrando a cada ficha individual; sin ese paso, la antigüedad y las descripciones quedaban completamente vacías.

6. Desafíos técnicos encontrados

6.1 Compresión Brotli — el bug silencioso

Síntoma. Tres de los cuatro portales devolvían cero avisos. Status HTTP 200, respuestas de unos 290 KB, ninguna excepción. Todo indicaba un cambio de selectores.

Diagnóstico. Al inspeccionar el contenido guardado, era **78% de bytes no imprimibles**: no era HTML sino un blob binario.

Causa. El scraper declaraba aceptar compresión Brotli sin tener instalada la librería para descomprimirla. El servidor toma la palabra y responde comprimido; la librería HTTP no sabe decodificarlo y entrega los bytes crudos. Argenprop nunca falló porque su CDN devuelve gzip, que la librería estándar sí descomprime — esa asimetría hacía parecer que el problema estaba en los otros portales.

Por qué es insidioso. No falla ruidosamente. Sin excepción, con status 200 y un cuerpo del tamaño esperable, es indistinguible de un problema de selectores.

Solución. Dos capas: declarar únicamente los codecs que el entorno puede descomprimir, verificándolo en tiempo de ejecución, y una red de seguridad que detecta un cuerpo binario y lo descomprime a mano. Probado contra los cuatro algoritmos de compresión habituales.

6.2 Huella TLS

Las librerías HTTP estándar tienen una firma de conexión TLS que no coincide con la de ningún navegador real. Los sistemas anti-bot la detectan **en el handshake, antes de leer un solo header**, por lo que declarar un User-Agent de Chrome no ayuda. Se resolvió replicando el handshake exacto de un navegador.

6.3 Zonaprop y DataDome

El portal de mayor volumen del mercado es también el más protegido: fingerprinting de TLS, challenge de JavaScript, rate limiting por IP y captcha. Ninguna librería HTTP resuelve el challenge, porque requiere ejecutar el JavaScript. Se implementó un plan alternativo con navegador automatizado, que funciona, pero la fragilidad del enfoque sumada a la decisión de fuente única llevó a descartar el portal.

6.4 API oficial de MercadoLibre

MercadoLibre cerró el acceso anónimo a su API pública; hoy exige un token de aplicación registrada. Por eso se extrajo desde HTML. La salida limpia sería tramitar credenciales de desarrollador.

7. Fuentes externas previstas

Bases públicas identificadas para el enriquecimiento, cada una justificada por la hipótesis o pregunta que permite responder. El cruce es posible porque el 99,9% de los avisos tiene coordenadas geográficas.

Fuente	Qué aporta	Para qué
Bocas de subte (BA Data)	Coordenadas de las 379 bocas	Validar H2: distancia al transporte y su radio de influencia
Estaciones ferroviarias (BA Data)	Coordenadas de estaciones	Completar la accesibilidad en zonas sin subte
Espacios verdes (BA Data)	Polígonos de plazas y parques	Medir la prima por cercanía a espacio verde
Polígonos de barrios (BA Data)	Geometrías oficiales	Validar la asignación de barrio y habilitar mapas coropléticos
Delitos por comuna (BA Data)	Hechos registrados	Construir un índice de seguridad por zona
Tipo de cambio (API BCRA)	Serie ARS/USD	Convertir alquileres en pesos y medir la sensibilidad del KPI
Censo 2022 (INDEC)	Nivel socioeconómico por radio censal	Segmentar la demanda potencial de alquiler

8. Hoja de ruta

Tareas analíticas previstas para las etapas siguientes del proyecto.

Etapas	Tareas
Curaduría del dato	Tratamiento de faltantes y outliers con justificación técnica; normalización monetaria; detección de errores de carga; filtrado de tipologías fuera de alcance
Ingeniería de variables	Materialización de los KPIs definidos; construcción de variables derivadas; minería de descripciones con RegEx
Análisis exploratorio	Estadísticos de resumen robustos; distribuciones por barrio y tipología; matrices de correlación; narrativa visual
Inferencia	Tests estadísticos formales sobre las cuatro hipótesis, documentando p-valor y decisión sobre la hipótesis nula
Fusión espacial	Cruce de coordenadas con las fuentes externas de la sección 7
Reducción y clustering	PCA y MCA para sintetizar atributos dispersos en índices interpretables; segmentación de micro-mercados
Tablero y cierre	Dashboard interactivo e informe final orientado al inversor

Dependencia crítica

El análisis temporal —tiempo de publicación como proxy del *time to sell*, evolución de precios, probabilidad de colocación en 30 o 60 días— requiere **recolección periódica**. Si no se inicia un relevamiento recurrente en las próximas semanas, esas preguntas quedan fuera de alcance de forma definitiva: no pueden reconstruirse hacia atrás.

Reproducibilidad

Toda la extracción es reproducible desde el repositorio con dos comandos: uno verifica la lógica de parseo sin tocar la red, y el otro ejecuta el relevamiento completo. El código incluye reintentos con backoff, checkpoints ante interrupciones y deduplicación automática.