



Analítica Descriptiva 82.04

Inteligencia de Mercado Inmobiliario – Informe grupal

Segundo cuatrimestre de 2026

Grupo N°: 02

APELLIDO Y NOMBRES	Nº DE LEGAJO
Caveda Heins, Nicolás Manuel	66420
Naymark, Ezequiel	66483
Lladhon, Máximo	66571
Berezovsky, Iael Denise	66850

Plazo de entrega: 09/09/2026

Resumen ejecutivo

El mercado inmobiliario argentino es el destino habitual del ahorro en dólares, pero es un mercado opaco: no existe un registro público de precios de cierre, la oferta está dispersa en decenas de portales con criterios distintos y la asimetría de información favorece sistemáticamente a quien vende.

El pequeño inversor decide, con información anecdótica, una operación que compromete el ahorro de toda una vida. No existe una fuente pública que relacione, para un mismo tipo de inmueble y una misma zona, el precio de venta con el de alquiler, y esa relación es, precisamente, la que determina si una compra es un buen negocio.

Esta primera etapa se ocupó de construir esa materia prima. Relevamos 14.867 avisos con 55 variables cada uno, cubriendo los 48 barrios de la Ciudad en operaciones de venta y alquiler. Donde antes había avisos sueltos dispersos en una web, ahora hay una base estructurada y reproducible.

En términos conceptuales, esta etapa dejó definidos al cliente (el pequeño inversor particular que compra una unidad para renta), el objetivo (estimar la rentabilidad esperada junto con su margen de error), los cuatro indicadores que se van a usar para medirla, cuatro hipótesis con su criterio de validación ya fijado, y tres fuentes externas del GCBA que ya están descargadas para enriquecer el análisis más adelante.


En términos concretos, se evaluaron cuatro portales inmobiliarios y se eligió uno por su consistencia interna; se construyó un dataset de 14.867 avisos por 55 variables con cobertura del 100% de los barrios, que combina doce variables numéricas, ocho textuales, dos ordinales y veintitrés dicotómicas; se diagnosticaron y resolvieron cuatro desafíos técnicos de la extracción; y todo el proceso quedó documentado y es reproducible con dos comandos.

El hallazgo más revelador de esta etapa fue técnico antes que comercial: tres de los cuatro portales devolvían cero avisos sin generar ningún error. El status HTTP era 200, las respuestas tenían un tamaño normal y no aparecía ninguna excepción: todo indicaba que el problema estaba en los selectores. El diagnóstico reveló, en cambio, que el contenido guardado era en un 78% bytes no imprimibles: no era HTML, sino un blob binario comprimido que la librería no sabía descomprimir. Un fallo silencioso, indistinguible de un cambio de estructura en la página, que se cuenta con más detalle en la sección 5.

1. El problema y el cliente

La asimetría de información domina el mercado inmobiliario: quien vende sabe más que quien compra. Afirmaciones como *“comprá en Palermo que siempre se alquila”* circulan como sentido común sin ningún respaldo cuantitativo, y sin embargo son la base sobre la que se deciden inversiones de seis cifras.

El interlocutor de este proyecto es el pequeño inversor particular: una persona con ahorros en dólares, típicamente entre USD 80.000 y 200.000, que evalúa comprar una sola unidad en CABA para ponerla en alquiler. No es un desarrollador ni un fondo: hace esta operación una o dos veces en toda su vida, lo que cambia por completo las reglas del análisis. Como compra una única unidad y no una cartera, no puede diversificar: cualquier error de estimación impacta el 100% de su capital. Su ticket, además, es acotado: el 57% de la oferta relevada está por debajo de los USD 150.000, así que ese es efectivamente su universo de decisión. Prioriza la previsibilidad por sobre el rendimiento marginal (un punto extra de renta no compensa tres meses de vacancia) y, a diferencia de un desarrollador, no tiene acceso a información profesional: decide con los mismos avisos públicos que releva este proyecto.



El universo de decisión del pequeño inversor. La oferta se concentra en el rango accesible para el perfil definido, con una mediana de USD 130.000 y una cola derecha larga de propiedades premium que quedan fuera de su alcance.

2. Objetivo, alcance y usuario

El objetivo de este trabajo es dotar al pequeño inversor de una estimación cuantificada de la rentabilidad esperada de cualquier inmueble en venta de CABA, junto con el margen de error de esa estimación, para que pueda comparar alternativas concretas sobre evidencia en lugar de sobre percepciones del mercado. Eso supone tres capacidades: estimar cuánto se alquilaría hoy un inmueble publicado en venta, comparar barrios y tipologías distinguiendo la señal real del ruido estadístico, y advertir explícitamente la incertidumbre de cada estimación.

El análisis incluye avisos de venta y alquiler publicados en CABA por RE/MAX, relevados en agosto de 2026, que cubren los 48 barrios y las 15 comunas. Quedan afuera del análisis posterior las cocheras, oficinas, locales, terrenos, depósitos y hoteles, porque no responden a la tesis de inversión del cliente definido; se capturan igual durante la extracción y se filtran recién en la etapa de curaduría.

Conviene declarar también las limitaciones del enfoque. Al tratarse de una fuente única, lo que describe la base es la cartera de RE/MAX y no el mercado completo. El corte temporal es único, así que no permite construir series ni capturar estacionalidad. Los precios son de publicación, no de cierre (que suele ser menor), y como la base tiene 7,4 avisos de venta por cada uno de alquiler, esa proporción va a condicionar cómo se estime el alquiler esperado en las etapas siguientes.

El usuario final de este análisis no programa, no interpreta un coeficiente de determinación y no va a leer un notebook. Eso le impone tres restricciones de diseño a las etapas siguientes: los resultados tienen que ser legibles sin conocimiento estadístico, la incertidumbre tiene que expresarse en las unidades de su decisión, y la herramienta tiene que responder su pregunta real: *¿este departamento es una buena compra?* No una pregunta agregada sobre el mercado en general. Vale aclarar, para no generar expectativas de más, qué es lo que este análisis no se propone: no busca estimar la revalorización del inmueble, ni sustituye la inspección física o la verificación legal, ni pretende predecir precios de cierre.

3. KPIs

Cada indicador que se define a continuación existe en dos planos: la fórmula que lo calcula y la decisión que le permite tomar al inversor. Se definen en esta etapa y se van a calcular sobre el dataset en las siguientes.

La rentabilidad bruta anual se calcula como el alquiler mensual estimado multiplicado por doce, dividido el precio de venta, por cien. Es el rendimiento del capital antes de costos, y funciona como indicador de cribado: permite descartar rápido lo que rinde por debajo del mercado, aunque no es lo que el inversor efectivamente va a cobrar.

La rentabilidad neta anual surge de multiplicar la bruta por $(1 - \text{vacancia})$ y por $(1 - \text{gastos})$. Es el ingreso que efectivamente queda en el bolsillo, el número que se compara contra un plazo fijo o un bono. Descuenta la vacancia (los meses sin inquilino entre contrato y contrato) y los gastos del propietario: administración, ABL, expensas extraordinarias y mantenimiento. Las expensas ordinarias no se descuentan porque en CABA las paga el inquilino.

Los meses de repago se obtienen dividiendo el precio de venta por el alquiler mensual estimado, y responden a una pregunta más intuitiva que un porcentaje: cuánto tarda la inversión en devolver el capital vía renta. También funcionan como control de sanidad de los datos, porque un repago anormalmente corto suele señalar un error de carga.

Por último, la banda de incertidumbre multiplica la rentabilidad bruta por $(1 \pm \text{el error de estimación})$. Existe para evitar decidir sobre diferencias que no son reales: si dos propiedades estiman rentabilidades parecidas y el margen de error las solapa, esa diferencia es indistinguible del ruido. Para alguien que compra una sola propiedad y no puede promediar errores entre varias, esta banda es tan importante como el rendimiento mismo.

4. Hipótesis a validar


Antes de analizar los datos se declararon cuatro hipótesis, cada una con su criterio de validación definido de antemano. La primera (H1) sostiene que la rentabilidad bruta es inversamente proporcional al precio del metro cuadrado del barrio, y se va a testear con una correlación de Spearman entre el precio mediano por m² y la rentabilidad, barrio por barrio. La segunda (H2) plantea que el precio por m² decrece con la distancia a una boca de subte dentro de un radio de influencia, algo que se valida cruzando la ubicación de cada aviso con las bocas de subte del GCBA y controlando por barrio. La tercera (H3) propone que los inmuebles “a reciclar” cotizan con descuento sobre su valor esperado, lo que se comprueba comparando el precio observado contra el que predice un modelo construido solo a partir de las características del inmueble. La cuarta (H4), finalmente, sostiene que la antigüedad pesa más sobre el precio de venta que sobre el de alquiler, y se testea comparando el coeficiente de antigüedad entre dos modelos análogos.

Estas hipótesis se despliegan, además, en cuatro niveles de análisis que van a ir apareciendo a lo largo del trabajo. En el nivel descriptivo interesa el precio por m² y su dispersión por barrio, su variación según la antigüedad, la distribución espacial de la oferta, la frecuencia de amenities y el porcentaje de stock apto para crédito. En el diagnóstico, qué características explican el precio de alquiler, cuánto pesa la ubicación frente a los atributos del inmueble y qué prima paga el mercado por cochera, balcón o seguridad. En el predictivo, cuánto se alquilaría hoy un inmueble publicado en venta, qué rentabilidad esperada tiene cada propiedad y con qué margen de error. Y en el prescriptivo, en qué barrios conviene comprar, qué combinación de barrio, tipología y superficie optimiza la relación entre rentabilidad y riesgo, y si conviene pagar la prima que piden los amenities.

5. Construcción de la base de datos

Se desarrollaron extractores para cuatro portales: Argenprop, MercadoLibre, Zonaprop y RE/MAX. Finalmente se optó por RE/MAX, a través de su API pública. Argenprop, con HTML server-rendered, y MercadoLibre, combinando HTML con JSON embebido, resultaron ambos funcionales, pero se descartaron por un problema de unicidad. Zonaprop, que usa ese mismo esquema de HTML con JSON embebido, quedó bloqueado por DataDome. RE/MAX, en cambio, expone una API JSON pública y fue la fuente elegida.


Consolidar cuatro portales exige cruzar por dirección, superficie y precio para detectar cuándo el mismo inmueble está publicado en varios sitios a la vez. Ese cruce es impreciso y arrastra un error difícil de cuantificar; a eso se suma que cada portal normaliza distinto los barrios, las superficies y las tipologías. Por eso se priorizó la consistencia interna del dataset por sobre el volumen bruto de avisos. Como ventaja adicional, RE/MAX resultó ser la única de las cuatro fuentes que expone latitud y longitud confiables, lo que habilita los cruces espaciales previstos para las etapas siguientes.



Más allá de la elección del portal, vale la pena detenerse en qué tipo de datos terminó capturando el esquema unificado. Cubre los cuatro tipos que exige la consigna: doce variables numéricas (precio, superficie, ambientes, antigüedad, coordenadas), ocho textuales y categóricas

(operación, tipo, barrio, calle, descripción), dos ordinales (comuna, piso) y veintitrés dicotómicas (cochera, balcón, amenities, apto crédito, a reciclar, entre otras).

El precio se capturó separado en valor numérico y moneda, no como una cadena de texto: una mejora sobre el script base provisto, que lo dejaba como “USD 145.000”, imposible de promediar. El barrio se normalizó contra los 48 barrios oficiales de CABA, resolviendo alias como *Palermo Hollywood* hacia *Palermo*, u *Once* hacia *Balvanera*, y de ese barrio normalizado se derivó la comuna. Las veintitrés variables dicotómicas, por su parte, se construyeron aplicando expresiones regulares sobre el texto libre del título, la descripción y los detalles de cada aviso.



Las variables de interés declaradas (barrio, superficie, ambientes, antigüedad y precio) se capturaron con una cobertura alta. Esa captura exigió entrar a cada ficha individual: sin ese paso, la antigüedad y las descripciones hubieran quedado completamente vacías.

6. Desafíos técnicos encontrados

6.1 Compresión Brotli

El primer desafío fue, también, el más difícil de encontrar. Tres de los cuatro portales devolvían cero avisos, pero sin generar ningún error: el status HTTP era 200, las respuestas rondaban los 290 KB y no saltaba ninguna excepción. Todo apuntaba a un cambio de selectores. Al inspeccionar el contenido guardado, sin embargo, resultó que un 78% de los bytes eran no imprimibles: no era HTML, sino un blob binario.

La causa terminó siendo más simple, y más sutil, de lo esperado: el scraper declaraba aceptar compresión Brotli sin tener instalada la librería necesaria para descomprimirla. El servidor toma la palabra y responde comprimido; la librería HTTP no sabe decodificarlo y entrega los bytes crudos tal cual llegan. Argenprop nunca falló por una razón casi accidental (su CDN devuelve gzip, que la librería estándar sí sabe descomprimir), y esa asimetría fue justamente lo que, al principio, hizo parecer que el problema estaba en los otros portales.

Lo insidioso de este bug es que no falla de manera ruidosa. Sin ninguna excepción, con status 200 y un cuerpo del tamaño esperable, resulta prácticamente indistinguible de un problema de selectores. La solución terminó teniendo dos capas: declarar únicamente los codecs que el entorno puede efectivamente descomprimir, verificándolo en tiempo de ejecución, y agregar una red de seguridad que detecta un cuerpo binario y lo descomprime a mano. Se probó contra los cuatro algoritmos de compresión habituales.

6.2 Huella TLS

Las librerías HTTP estándar dejan una firma de conexión TLS que no coincide con la de ningún navegador real, y los sistemas anti-bot la detectan directamente en el handshake, antes incluso de leer un solo header, y por eso declarar un User-Agent de Chrome no alcanza. La solución fue replicar el handshake exacto de un navegador.

6.3 Zonaprop y DataDome

El portal de mayor volumen del mercado resultó ser también el más protegido: combina fingerprinting de TLS, un challenge de JavaScript, rate limiting por IP y captcha. Ninguna librería HTTP puede resolver ese challenge, porque hace falta ejecutar el JavaScript en un entorno real. Se llegó a implementar un plan alternativo con navegador automatizado que efectivamente funciona, pero la fragilidad de ese enfoque, sumada a la decisión de trabajar con una fuente única, llevó a descartar el portal.

6.4 API oficial de MercadoLibre

MercadoLibre cerró hace tiempo el acceso anónimo a su API pública y hoy exige un token de aplicación registrada, así que la extracción se hizo desde el HTML de la página. La salida más prolija sería, en algún momento, tramitar credenciales de desarrollador.

7. Fuentes externas previstas

Ya se descargaron tres bases públicas del Gobierno de la Ciudad pensadas para el enriquecimiento posterior, cada una justificada por la hipótesis o la pregunta que permite responder. Este cruce es posible porque el 99,9% de los avisos tiene coordenadas geográficas propias, lo que permite calcular distancias sin necesidad de geocodificar ninguna dirección.

La base de bocas de subte, con las coordenadas de las 379 bocas de la Ciudad, va a servir para validar H2: la distancia al transporte y su radio de influencia. La de estaciones ferroviarias, con 301 estaciones, va a completar la accesibilidad en las zonas que no tienen cobertura de subte. Y la de espacios verdes públicos, con los polígonos de 2.176 plazas y parques, va a permitir medir si existe una prima por cercanía a un espacio verde.

8. Hoja de ruta

Quedan definidas siete etapas para lo que sigue del proyecto. La curaduría del dato se va a ocupar del tratamiento de faltantes y outliers con justificación técnica, la normalización monetaria, la detección de errores de carga y el filtrado de las tipologías que quedan fuera de alcance. La ingeniería de variables materializa los KPIs ya definidos, construye las variables derivadas que hagan falta y hace minería de las descripciones con expresiones regulares. El análisis exploratorio aporta estadísticos de resumen robustos, distribuciones por barrio y tipología, matrices de correlación y una narrativa visual del conjunto.

La inferencia corre los tests estadísticos formales sobre las cuatro hipótesis, documentando el p-valor y la decisión sobre la hipótesis nula en cada caso. La fusión espacial cruza las coordenadas del dataset con las tres fuentes externas descriptas en la sección anterior. La reducción y clustering aplica PCA y MCA para sintetizar atributos dispersos en índices interpretables, y a partir de ahí segmenta micro-mercados. Y la última etapa arma el tablero interactivo y el informe final orientado al inversor, que cierra el proyecto.

Toda la extracción, mientras tanto, es reproducible desde el repositorio con solo dos comandos: uno verifica la lógica de parseo sin tocar la red, y el otro ejecuta el relevamiento completo. El código incluye reintentos con backoff, checkpoints ante interrupciones y deduplicación automática.